



$$y = \theta_1 x + \theta_0$$

$$\rightarrow \theta = \theta - \alpha \cdot x^{(i)} (y^{(i)} - \theta_1 x^{(i)} - \theta_0)$$

반복. 많은


$\theta_1, \theta_0$  의 cost function이 작아지고  
3차원에서는 그래프를 볼 수 없기 때문에  
방법이 필요. 



1/20

$x_2$	$x_1$	$x$	$y$
1	2	1	2
0	3	2	3
1	4	3	4
2	5	4	5

+ 여기 다른 변수  
넣어주기.  $\rightarrow$  linear  
회귀선 방향이 있네.



H, W가 되면 MLP.

$$y = w x + b.$$

$$y = \theta_2 x_2 + \theta_1 x_1 + b$$

$y \propto x_2$

$y \propto x_1$

$x_2$ 와  $x_1$ 은 서로 상관관계가 없어야.  
Correlation


$\rightarrow$  없어야. 가능.

서로 독립이라는 가정.

$$x_2 \sim x_1$$

$\rightarrow$  covariance  
correlation.

np.corrcoef( $x_2, x_1$ )



상관관계 0 이면

$\rightarrow$  linear regression에  
들어감 안된다는 뜻.

파제!! death rate  $\downarrow$ . linear 하다고 가정하긴.  $\downarrow$ 는  $\downarrow$ 이.

feature가 여러개 있다고 다 하면 x.

왜? 저번 정귀하는 pre-processing. 이것과 같은 개념.

$x_1 \sim x_n$  사이 상관관계 있는 것 빼야.  $\rightarrow$  linear reg. 망할 수.

$$y = \theta_2 x_2 + \theta_1 x_1 + b$$

각각의  $m, \sigma$  맞춰주어야  
( $\because \theta_2$ 에 미치는 영향이 너무 direct?)  
learning에



$\forall x_i$ 의  $m, \sigma$ 를 보고 corr도 보고

	$x_1 \dots x_n$
$x_1$	상관관계가 높다? 둘다 넣으면 x.
$\vdots$	
$x_n$	
$\downarrow$	
조금 더 target과 유사도가 높은 $x_i$ 를 넣을 것.	

$$y = \theta_2 x_2 + \theta_1 x_1 + \theta_0$$

$$\vec{\theta} = \begin{bmatrix} \theta_2 \\ \theta_1 \\ \theta_0 \end{bmatrix}$$

$$\vec{x} = \begin{bmatrix} x_2 \\ x_1 \\ 1 \end{bmatrix}$$

$1 \rightarrow$  dummy  
var.  
(하나라도 없으면 1)

$$\vec{\theta}^T \cdot \vec{x}$$

$$\theta_2 \rightarrow z_{1-1} = \theta_2 x_2$$

$$\theta_1 \rightarrow z_{1-2} = \theta_1 x_1$$

$$\theta_0$$

$$z_2 = z_{1-1} + z_{1-2} + \theta_0$$

$$x_2 =$$

$$x_1 =$$

$$y = x_1 + x_2 + 1 + \text{noise}$$

$$J(\theta_2, \theta_1, \theta_0)$$

$$\text{pred} = \hat{y} = \theta_2 x_2 + \theta_1 x_1 + \theta_0$$

$$\frac{1}{N} \sum (y - \hat{y})^2 \rightarrow \frac{\partial}{\partial \theta_2} = 2(y - \hat{y}) \cdot (-x_2)$$

$$\frac{\partial}{\partial \theta_1} = 2(y - \hat{y}) \cdot (-x_1)$$

$$\frac{\partial}{\partial \theta_0} = 2(y - \hat{y}) \cdot (-1)$$

Jacobian. matrix.

$$\begin{bmatrix} x_1^{(1)} & x_1^{(2)} \\ x_2^{(1)} & x_2^{(2)} \end{bmatrix}$$

$$[y^{(1)} \ y^{(2)}]$$

^ feature scaling 안해주면?  
 $\theta$ 가 3차원시

